



南京大學

智能计算系统  
实验操作手册

实验序号 四  
实验名称 基于 MindSpore 实现  
GPT 模型的训练和推理  
院 系 计算机学院

2025 年 12 月 4 日

# 目 录

<b>实验四 基于 MindSpore 实现 GPT 模型的训练和推理</b>	<b>1</b>
4.1 实验目的 . . . . .	1
4.2 背景介绍 . . . . .	1
4.2.1 MindSpore . . . . .	1
4.2.2 ModelArts . . . . .	2
4.2.3 Transformer 架构和 GPT 预训练模型 . . . . .	5
4.2.4 语言建模任务 . . . . .	6
4.2.5 大语言模型（Large Language Model, LLM） . . . . .	7
4.3 实验环境 . . . . .	8
4.4 实验内容 . . . . .	8
4.5 实验步骤 . . . . .	8
4.5.1 实验运行 . . . . .	9
4.6 评分指标 . . . . .	10
4.7 实验思考 . . . . .	10

# 实验四 基于 MindSpore 实现 GPT 模型的训练和推理

## 4.1 实验目的

本实验的目的是掌握 MindSpore 深度学习框架的基本使用，了解基于 Transformer 架构的 GPT 模型基本架构以及语言建模任务，使用 MindSpore 构建简易 GPT 模型，并在给定的《金庸武侠小说》数据集上，通过语言建模任务预训练 GPT 模型。然后利用预训练后的 GPT 模型完成一个金庸风格的文本续写任务。具体包括：

- 1、熟悉和使用 MindSpore 框架、昇腾训练卡和华为云 ModelArts，熟悉 MindSpore 常见 API 的使用方法，熟悉 ModelArts 一站式模型训练和部署平台。
- 2、使用 MindSpore 构建 GPT 模型，并完成模型的训练和推理。
- 3、基于预训练后的模型，设计和完成一个金庸风格的文本续写任务。

## 4.2 背景介绍

### 4.2.1 MindSpore

MindSpore 是华为推出的深度学习框架，拥有自动微分、并行加持，一次训练，可多场景部署的特性。为全场景 AI 的模型开发、模型运行、模型部署提供端到端能力。MindSpore 支持深度学习算法在 Ascend、GPU、CPU 等硬件平台上开发和部署。



如需查看详情，请参见如下资源：

- MindSpore 教程
- MindSpore Python API

### 4.2.2 ModelArts

ModelArts 是华为云推出的面向 AI 开发者的一站式开发平台，涵盖了 AI 开发的各个环节，包括数据处理、算法开发、模型训练、模型部署等。从技术上看，ModelArts 底层支持各种异构计算资源，开发者可以根据需要灵活选择使用，而不需要关心底层的技术。同时，ModelArts 支持 Tensorflow、PyTorch、MindSpore 等主流开源的 AI 开发框架。




图 4-1 ModelArts 控制台页面

## OBS 桶

ModelArts 使用对象存储服务（Object Storage Service，简称 OBS）进行数据存储及模型的备份。OBS 的基本组成是桶和对象。桶是 OBS 中存储对象的容器，对象是代码和数据集文件，每个桶都有自己的存储类别、访问权限等属性。ModelArts 通过访问 OBS 桶中对应的文件来访问数据。因此，在开始训练任务之前，需要将数据和训练脚本上传至 OBS。

上传步骤：

- (1) 打开 OBS 控制台，创建 OBS 桶（建议区域均选择“西南-贵阳一”，空闲资源较多，且成本较低）。

(2) 上传项目目录，包含代码、数据集、以及其他辅助目录（如存放 log 日志文件的目录和存放输出文件的目录）。




图 4-2 OBS 目录示例

## ModelArts 训练和评估页面

在 ModelArts 界面中选择模型训练、训练作业、创建训练作业进入训练作业创建页面，填入相关信息之后，即可启动训练任务。（注意启动方式中选择“Ascend-Powered-Engine”和“mindspore\_2.4.10...”）




图 4-3 ModelArts 训练作业

## 通过 Notebook 调试代码

在开始训练和评估之前，通常需要先调试代码，以保证代码的正确性以及执行效率。在 ModelArts 平台上，可以通过平台提供的 Nootbook（Jupyter Lab

环境) 进行代码调试和测试。选择“开发空间”、“Notebook”、“创建 Notebook”。创建 Notebook 时, 注意选择与训练环境一致的镜像和计算资源规格(mindspore\_2.4.10-cann\_8.0.0\_xxxx)。




图 4-4 Notebook 创建

进入 Notebook 之后, 可以通过 Jupyter Notebook 和终端调试代码。注意, 可以通过执行以下代码, 将 OBS 中的项目文件, 拷贝到当前 Notebook 的工作目录中, 以避免重复上传。

```
1 import moxing
2 moxing.file.copy_parallel("obs://(OBS桶名称)/(项目目录)", "./(Notebook中的项目目录)")
```

**注意:** 在 Notebook 中更新代码之后, 需要将更新同步到 OBS 中的项目目录中, 以便在训练和推理中使用。此外, 整个训练和推理过程也可以在 Notebook




图 4-5 Notebook 页面

中执行。更推荐尝试 ModelArts 提供的训练和推理功能，以体验一站式 AI 开发平台的便捷性。

同时，ModelArts 还提供了 VS Code 扩展和 PyCharm 插件等方式辅助开发和调试代码，感兴趣的同学可以自行了解和使用。

### 4.2.3 Transformer 架构和 GPT 预训练模型

Transformer 架构通过注意力机制捕捉输入序列中不同位置之间的依赖关系，从而实现对序列数据（如文本）的高效处理，已经在文本和图像任务中展现出。




图 4-6 Transformer 架构

GPT (Generative Pre-trained Transformer) 是一种基于 Transformer 架构的语言模型，通过大量的文本数据进行预训练，使模型能够理解和生成自然语言。当模型参数量扩展到一定规模后，GPT 模型就拥有了良好的上下文学习 (In-context Learning) 能力，这也是现代大模型技术的基础。




图 4-7 GPT 模型

#### 4.2.4 语言建模任务

GPT 和 Llama 模型的预训练，是通过无监督的语言建模的任务，简而言之，通过一个句子中前面所有的 token 预测下一个 token。即，对于一个序列  $(w_1, w_2, \dots, w_T)$ ，语言模型试图估计：

$$P(w_1, w_2, \dots, w_T) = P(w_1)P(w_2|w_1)P(w_3|w_1, w_2) \cdots P(w_T|w_1, \dots, w_{T-1})$$

因此，除了基本的 Transformer 架构之外，在实现中，需要注意以下两点：

(1) 输入数据和标签的构建：为了实现上述语言建模任务，假设从数据集中获取到一个序列 [0, 1, 2, 3, 4]，则给模型的输入应该是 [0, 1, 2, 3]，而模型预测所对应的标签则应该是 [1, 2, 3, 4]。

(2) 因果自注意力：在自注意力计算时，为了避免当前 tokens 提前看到后面的信息，需要对注意力计算做掩码，即使得当前 token 对后面 tokens 的

注意力分数都为 0。

### 4.2.5 大语言模型 (Large Language Model, LLM)

大语言模型实际上就是参数和训练数据规模大得多的类 GPT 模型，在本质上是一个概率模型。尽管今天的 ChatGPT 或 Claude 表现出了惊人的推理和对话能力，但它们的核心任务从未改变：给定一段文本序列，预测下一个最可能出现的词 (Token)。

GPT 的发展史就是 LLM 从量变到质变的过程：

- GPT-1 (2018):
  - 理念：先预训练，后微调 (Pre-train then Fine-tune)。先在无标注的大规模文本上学习语言知识，再在特定任务上微调。
  - 参数量：1.17 亿。
- GPT-2 (2019):
  - 理念：Zero-shot (零样本学习)。OpenAI 发现，只要模型够大、数据够多，不需要针对特定任务微调，模型就能通过“续写”完成翻译、问答等任务。
  - 参数量：15 亿。
- GPT-3 (2020):
  - 理念：暴力美学与 In-context Learning (上下文学习)。参数量扩大了 100 倍。模型展现出了惊人的少样本学习能力，仅需在提示词中给出一两个例子，它就能学会新任务。
  - 参数量：1750 亿。
- InstructGPT / ChatGPT (2022):
  - 关键一跃：RLHF (基于人类反馈的强化学习)。之前的 GPT-3 虽然强大，但经常胡言乱语。RLHF 引入了人类的偏好，将模型的输出“对齐”(Alignment) 到人类的价值观和指令上，使其变得有用且安全。
  - 参数量：同 GPT-3。

### 4.3 实验环境

环境：华为云 ModelArts 平台

环境依赖：

表 4-1 环境依赖

名称	版本
Python	3.10
MindSpore	2.4.10

**数据集：**金庸武侠小说全本。使用金庸武侠小说作为预训练语料库。如果时间和余额充裕，可以考虑增加语料库，以提升模型的生成效果。反之，也可以自行选定其中的一本或者几本作为预训练数据集。预训练完成之后，使用模型进行金庸风格文本续写。

### 4.4 实验内容

本实验基于 Modelarts 平台，使用 MindSpore 深度学习框架，搭建小型 GPT 模型，并使用《金庸武侠小说》作为语料库，在 Ascend910 加速卡上进行预训练和推理。

### 4.5 实验步骤

代码目录：

```

1 JinYong_GPT
2   |- data           // 金庸小说数据集
3   |- dataset        // 存放 MindRecord 格式数据集文件
4     |- tokenizer.json // 存放 tokenizer 的词表
5     |- mindrecord    // MindRecord 格式数据集文件
6     |- mindrecord.db
7   |- generate.py    // 执行推理的代码
8   |- train.py       // 模型训练代码
9   |- src
10  |   |- dataset.py // 生成训练数据集
11  |   |- model.py   // 模型主体代码
12  |   |- preprocess.py // 数据预处理，生成 MindRecord 格式数据集文件

```

```

13 |   |- tokenizer.py // Tokenizer 定义和训练
14 |   \_ utils.py      // 工具方法
15 |- requirements.txt          // Python 依赖库

```

实验步骤如下：

- 1、选择金庸小说作为语料库，通过”src/tokenizer”训练和获取 Tokenizer。
- 2、选择金庸小说作为语料库，通过”src/pre\_process.py”预处理数据集，生成”MindRecord”格式数据集。（前两个步骤可以在 Notebook 中调试和执行，然后将生成的 MindRecord 文件上传到 OBS 中。）
- 3、搭建模型主体架构。
- 4、通过 ModelArts 执行训练代码”train.py”训练模型。（请注意在创建训练任务时，指定正确的 OBS 目录和训练参数。并且按照 ModelArts 要求的方式配置输入和输出路径。）




图 4-8 ModelArts 训练任务参数配置

- 5、执行推理代码”generate.py”，加载模型 ‘checkpoint’，测试小说续写任务。

**注意：**请先阅读和理解代码，尤其是各种目录和参数设置，切勿盲目运行。数据集预处理时间开销较大，可以在本地执行之后，再把生成的 MindRecord 文件上传到云端进行训练。

**注意：**所有代码参数和模型超参数都是可调的，请根据自己的需要以及时间预算和云平台余额，合理调整。

**注意：**必须使用基本的算子和接口实现 GPT 模型，禁止直接使用 MindSpore 提供的 Attention、Transformer 或 GPT 相关模块。

### 4.5.1 实验运行

通过 ModelArts 平台运行实验。请注意模型训练的时间开销，避免云平台欠费。预训练未必需要执行多个 epoch，甚至未必需要执行一个完整的 epoch，请根据自己的时间预算调整。

## 4.6 评分指标

评分指标分为两个部分，其中实验代码和结果占 90%，实验报告的撰写（包含实验思考部分）占 10%。实验结果的评分指标如下：

60-80：根据提示，完成 GPT 模型构建和预训练。

80-100：在预训练后的模型上，执行推理任务，构建一个文本续写应用。

## 4.7 实验思考

1. 你的 GPT 模型生成效果如何？如何进一步提升模型的生成效果？
2. 当前的基于汉字字符的 tokenizer 有何优缺点？是否可以设计更好的 tokenizer 方案？
3. 你的 GPT 模型参数量有多少？如果以 FP32 精度做训练，需要占用多少显存？如果有条件请观察使用不同超参数和模型参数量时，预训练和推理效率的变化情况。
4. 模型训练和推理中的静态图模式和动态图模式分别指什么？有何区别？你使用的是哪种模式？为什么？
5. 是否可以在你的预训练模型基础上，设计一些更有趣的应用？